

# LINGAM

石垣ゼミ3年  
名執祐矢

# 今までの要点

---

- ・ 相関関係があっても因果関係があるとは限らない  
(= 擬似相関)
- ・ 相関係数の値によって、因果関係の大きさが測れない

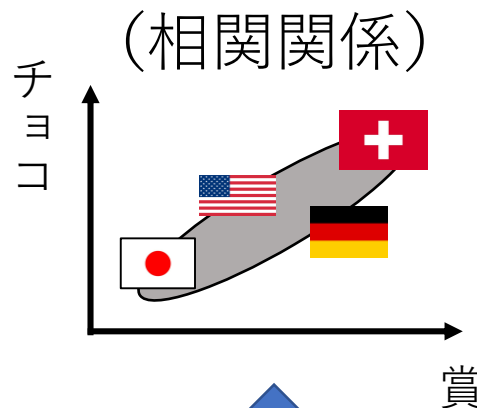
→ 背後に「未観測共通原因」の存在

→ 擬似相関を懐柔し、データから因果関係まで推測するための方法を研究するのが「統計的因果探索」

# 今までの要点（擬似相関）


チョコレートをたくさん食べている国ほど受賞者が多い

- ・ 四角で囲まれている変数：観測変数  
(データが収集される変数)
- ・ 点線の楕円で囲まれている変数  
：未観測変数 (データが収集されない変数)
- ・ 矢印の有無：因果関係の有無  
(始点が原因、終点が結果の変数)




相関係数 0.79  
P値 < 0.0001


複数の因果関係が  
同じ相関関係を与えうる



or




or



チョコレートをたくさん食べさせれば受賞者が増えるのか？  
(因果関係)


# 今までの要点 (擬似相関)

未観測共通要因




or

未観測共通要因



or

未観測共通要因



# 今までの要点（平均因果効果）

---

- ・ 変数 $x$ から変数 $y$ への因果効果の大きさを定量化  
→ 平均的な差を評価する

$$E(y|do(x = d)) - E(y|do(x = c)) \quad (\leftarrow \text{平均因果効果})$$


：  $M_{X=d}$  と  $M_{X=c}$  における  $y$  の期待値の差

※  $do(x = c)$ : ほかのどの変数がどんな値をとろうとも、変数 $x$ の値を定数 $c$ にとる（= 介入）


※  $M_{x=c}$ :  $x$  に介入して、その値を  $c$  に定めた構造方程式モデル

# 今までの要点（ランダム化実験）

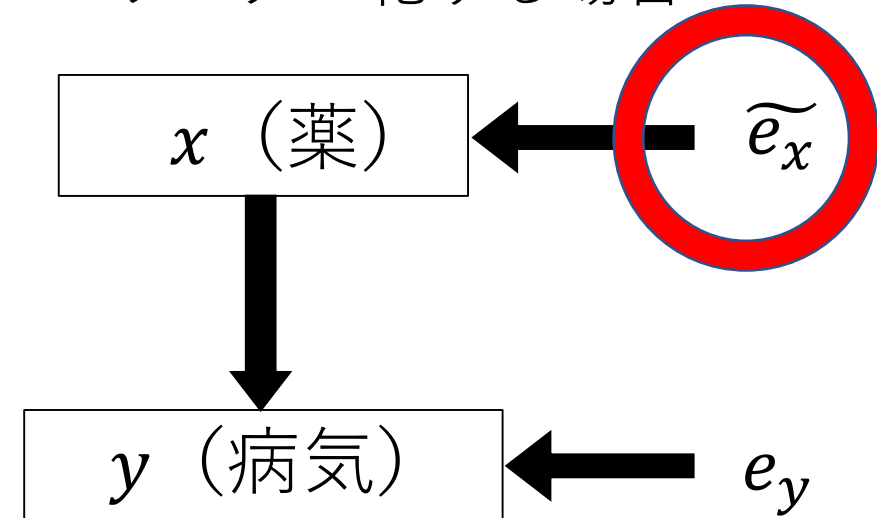
ランダム化しない場合



ランダム化



ランダム化する場合



- ・ 仮定1（事前知識）：時間的先行性  
→ ありうる **因果の向き** が決まる（病気→薬はありえない）
- ・ 仮定2：ランダム化  
→ 誤差変数が独立になる：**未観測共通原因**がない

# 今までの要点（ランダム化実験）

---

ランダム化実験：一般的に、

$$p(y|do(x = c)) = p(y|x = c)$$

∴誤差変数 $\widetilde{e}_x$ と $e_y$ が独立

$$p(y|x = 1) \neq p(y|x = 0)$$

→この集団において、薬を飲むかどうか、  
病気が治るかどうかの原因となる

(※ただし、倫理的・技術的観点からランダム化実験が困難な場合が多い  
例：「抑うつ気分」と「睡眠障害」)

# 今までの要点（因果探索の基本問題）


・  $x, y$  : 観測変数      ・  $z$  : 未観測共通要因      ・  $e_x, e_y$  : 誤差変数

モデルA : 
$$\begin{cases} x = f_x(z, e_x) \\ y = f_y(x, z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$


モデルB : 
$$\begin{cases} x = f_x(y, z, e_x) \\ y = f_y(z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$

モデルC : 
$$\begin{cases} x = f_x(z, e_x) \\ y = f_y(z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$


未観測共通要因



未観測共通要因



未観測共通要因





# 今までの要点（因果探索の基本問題）

性質1：自律性（介入してもほかは変わらない）

性質2：関数形と外生変数の分布が決まれば内生変数の分布が決まる

モデルA：

$$\begin{cases} x = f_x(z, e_x) \\ y = f_y(x, z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$


モデルB：

$$\begin{cases} x = f_x(y, z, e_x) \\ y = f_y(z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$


モデルC：

$$\begin{cases} x = f_x(z, e_x) \\ y = f_y(z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$


未観測共通要因



未観測共通要因



未観測共通要因



# 今までの要点（因果探索の基本問題）


→統計的因果探索：「『関数形』と『外生変数の分布』にどのような仮定が成り立てば、元の因果グラフをどの程度推測できるのか」を明らかにする

モデルA：
$$\begin{cases} x = f_x(z, e_x) \\ y = f_y(x, z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$


モデルB：
$$\begin{cases} x = f_x(y, z, e_x) \\ y = f_y(z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$

モデルC：
$$\begin{cases} x = f_x(z, e_x) \\ y = f_y(z, e_y) \\ p(z, e_x, e_y) = p(z)p(e_x)p(e_y) \end{cases}$$


未観測共通要因



未観測共通要因



未観測共通要因



# 今までの要点（3つのアプローチ）

---

## ①ノンパラメトリック・アプローチ

関数形：仮定なし                      外生変数の分布：仮定なし

（ただし、因果関係は一方向であり双方向ではない）

→3つのモデルのうち、どのモデルか推測できない

## ②パラメトリック・アプローチ

関数形：（主に）線形                      外生変数の分布：（主に）ガウス分布

→3つのモデルのうち、どのモデルか推測できない

## ③セミパラメトリック・アプローチ（特にLiNGAMアプローチ）

関数形：線形                      外生変数の分布：非ガウス（連続）分布

→3つのモデルのうち、どのモデルか推測できる

- ・ガウス分布（正規分布）  
：平均と分散共分散行列が  
定まれば分布形は一意に  
決まる

- ・非ガウス分布  
：歪度・尖度などのパラ  
メータをもつ  
→情報量が多い

# 今までの要点（識別可能性）

---

- ・ 因果グラフの構造が異なれば、観測変数の分布が必ず異なる  
→ 因果グラフは「識別可能」である

↑ 観測変数の分布の違いを手がかりに元の因果グラフを復元する、という前提からして重要

# 今までの要点（識別可能性）

---

- ・ 未観測共通原因がないと仮定

→ 「共通原因にあたる変数はすべて観測されており、かつ、変数間の全ての因果関係が未知である」とする

- ・ 各変数 $x_i (i = 1, \dots, p)$ の生成過程


→  $x_i = f_i(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_p, e_i) \quad (i = 1, \dots, p) \quad (\text{※入力時に } x_i \text{ を含まない})$

# 今までの要点（識別可能性）

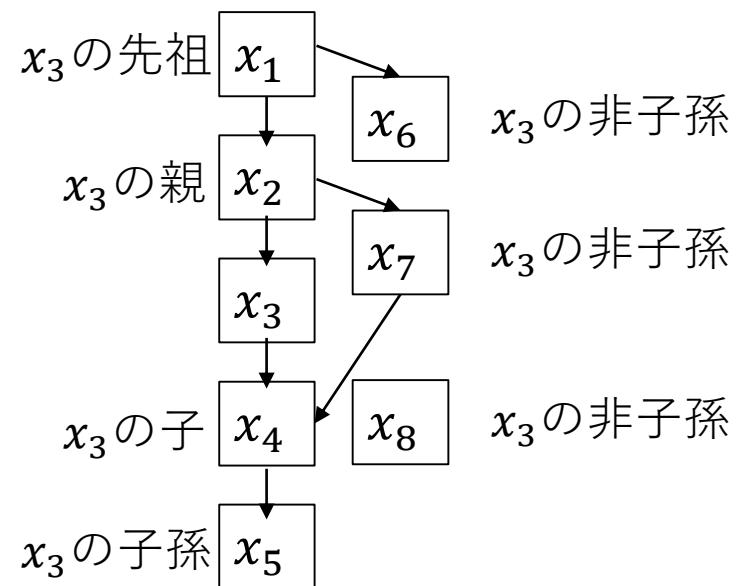


- ・ さらに因果関係の非巡回性・誤差変数の独立性を仮定

$$\rightarrow x_i = f_i(pa(x_i), e_i) \quad (i = 1, \dots, p)$$

・  $pa(x_i)$ : 観測変数 $x_i$ の親にあたる観測変数の集合



上の仮定  
を追加



# 今までの要点（識別可能性）

---

- ・ さらに誤差変数が連続変数、関数形が線形だと仮定。

$$\rightarrow x_i = \sum_{x_j \in pa(x_i)} b_{ij} x_j + e_i \quad (i = 1, \dots, p)$$

# 今までの要点（識別可能性）

---

- ・ノンパラメトリック・アプローチ

- 有向辺の向きを絞りきれない（詳細は省略）

- 因果グラフが識別可能ではない

- ・パラメトリック・アプローチ

- 同じ観測変数の分布を与えるような構造方程式モデルが複数ある（詳細は省略）

- 因果グラフが識別可能ではない

- ・セミパラメトリック・アプローチ（特にLiNGAMアプローチ）

- モデルが異なる場合に、観測変数の分布が必ず異なる

- 観測変数の分布からモデルを一意に推測できる場合がある（識別可能性あり）



# LiNGAMモデル

---

LiNGAMモデル：セミパラメトリックアプローチのうち、因果グラフが識別可能なモデル

→説明のために、「独立成分分析」を紹介

# 独立成分分析

---

- ・ 独立成分分析：未観測変数の値が混ざり合って、観測変数の値が生成されると考える

# 独立成分分析モデル

構造方程式


$$\begin{aligned}x_1 &= a_{11}s_1 + a_{12}s_2 \\x_2 &= a_{21}s_1 + a_{22}s_2\end{aligned}$$

$x_1, x_2$  : 観測変数

$a_{11}, a_{12}, a_{21}, a_{22}$  : 係数 (定数)

$s_1, s_2$  : 未観測の連続変数

因果グラフ



行列表現

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}}_A \underbrace{\begin{bmatrix} s_1 \\ s_2 \end{bmatrix}}_s$$

# 独立成分分析モデル

---

## ◎独立成分分析の目的

- ①モデルから生成されるデータ行列を用いて係数を推定
- ②未観測変数を復元

## ◎独立成分分析の特徴

- ①未観測変数 ( $s_1, s_2$ ) が独立
- ②かつ、非ガウス連続分布に従う

→独立性を利用して、未観測変数を復元

# 独立成分分析モデル

---

## ◎定義

一般に、 $p$ 個の観測変数 $x_i (i = 1, \dots, p; p \geq 2)$ の独立成分分析モデルは、

$$x_i = \sum_{j=1}^q a_{ij} s_j \quad (i = 1, \dots, p)$$

と表せる。

# 独立成分分析モデル

---

## ◎定義

行列を用いると、

$$x = As$$

と表せる。

A:混合行列（独立成分がどのように混ざり観測変数になるかを表す）

→Aは、列の順序と尺度を除いて識別可能

行列表現

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}}_A \underbrace{\begin{bmatrix} s_1 \\ s_2 \end{bmatrix}}_s$$

# 独立成分分析モデル

---

$$A_{ICA} = ADP$$

$A_{ICA}$  : 混合行列  $A$  と、列の順序と尺度だけが異なる可能性のある行列

$P$  :  $q \times q$  の置換行列 ( $A$  の列の順序を変えるかもしれない)

$D$  :  $q \times q$  の対角行列 ( $A$  の列の尺度を変えるかもしれない)


※  $P, D$  は未知

# 独立成分分析モデル

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}}_A \underbrace{\begin{bmatrix} s_1 \\ s_2 \end{bmatrix}}_s$$

  
Aの1列目  
と2列目  
を交換


$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} a_{12} & a_{11} \\ a_{22} & a_{21} \end{bmatrix}}_{A \text{ 置換後}} \underbrace{\begin{bmatrix} s_2 \\ s_1 \end{bmatrix}}_{S \text{ 置換後}}$$

  
 $s_1, s_2$ を  
置換

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}}_A \underbrace{\begin{bmatrix} s_1 \\ s_2 \end{bmatrix}}_s$$

  
Aの1列目  
をc倍

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} a_{11} \times c & a_{12} \\ a_{21} \times c & a_{22} \end{bmatrix}}_A \underbrace{\begin{bmatrix} s_1/c \\ s_2 \end{bmatrix}}_s$$

  
 $s_1$ を  
 $1/c$ 倍



# 独立成分分析モデル

---

→次のような行列とベクトルの組であれば、独立成分分析の仮定を満たす

$$\begin{aligned} A_{ICA} &= ADP \\ S_{ICA} &= P^T D^{-1} S \end{aligned}$$

$$\begin{aligned} (x &= As \\ &= ADPP^T D^{-1} S \\ &= (ADP)(P^T D^{-1} S) \\ &= A_{ICA} S_{ICA}) \end{aligned}$$

# 独立成分分析モデル

---

◎データから混合行列 $A$ を推定（※混合行列 $A$ は正方行列であると仮定）

→観測変数ベクトル $x$ を $p \times p$ の行列 $W$ で線形変換してつくったベクトル

$y = Wx$ によって、独立変数ベクトル $s$ を推定することを考える

$W = A^{-1}$ となれば、

$$s = Wx (= A^{-1}As = s)$$

によって、独立成分ベクトル $s$ を復元できる

# 独立成分分析モデル

---

(続き)

ベクトル $\mathbf{y}$ の成分 $y_j$  ( $j = 1, \dots, p$ ) の独立性が最大になるような $W$ を探す

∴ベクトル $\mathbf{y}$ で推定しようとしている独立成分ベクトル $\mathbf{s}$ の成分 $s_j$  ( $j = 1, \dots, p$ ) が独立

# 独立成分分析モデル

---

(続き)

独立性の指標：相互情報量

- ・ 非負の値をとる
- ・ 変数が独立のときに限り、相互情報量は 0

→相互情報量が最小になるように $W$ を推定

# 独立成分分析モデル

---

(続き)

ベクトル $\mathbf{y}$ の相互情報量

$$I(\mathbf{y}) = \left\{ \sum_{j=1}^q H(y_j) \right\} - H(\mathbf{y})$$

$$\rightarrow W_{ICA} = PDW = (PDA^{-1})$$

# LiNGAMモデル

LiNGAMモデル：セミパラメトリックアプローチのうち、因果グラフが識別可能なモデル


→係数行列 $B$ を観測変数の分布 $p(x)$ に基づいて一意に推定可能

構造方程式モデル

$$x_i = \sum_{j \neq i} b_{ij} x_j + e_i$$

行列表現

$$x = Bx + e$$



因果グラフ

—線形

—非巡回

—誤差変数 $e_i$

- ・非ガウス連続分布
- ・独立（未観測共通原因なし）

# LiNGAMモデル

---


- ・ 観測変数の「因果的順序」  
: その順序に従って変数を並び替えると、「順番が後の変数」が「順番が後の変数」の原因になることがない順序

→ 上のような観測変数  $x_1, x_2, \dots, x_p$  の順序を  $k(1), k(2), \dots, k(p)$  と表す。

# LiNGAMモデル

- ・ 構造方程式モデルと因果グラフ

$$\begin{aligned}x_1 &= 3x_3 + e_1 \\x_2 &= -5x_1 + e_2 \\x_3 &= e_3\end{aligned}$$



- ・ 因果順序  $k(3) = 1, k(1) = 2, k(2) = 3$  で並び替え

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} 0 & 0 & 3 \\ -5 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}}_B \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}}_x + \underbrace{\begin{bmatrix} e_1 \\ e_2 \\ e_3 \end{bmatrix}}_e$$


$$\underbrace{\begin{bmatrix} x_3 \\ x_1 \\ x_2 \end{bmatrix}}_{x_{\text{後}}} = \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ 3 & 0 & 0 \\ 0 & -5 & 0 \end{bmatrix}}_{B_{\text{後}}} \underbrace{\begin{bmatrix} x_3 \\ x_1 \\ x_2 \end{bmatrix}}_{x_{\text{後}}} + \underbrace{\begin{bmatrix} e_3 \\ e_1 \\ e_2 \end{bmatrix}}_{e_{\text{後}}}$$



# LiNGAMモデル

- ・ 構造方程式モデルと因果グラフ

$$\begin{aligned}x_1 &= e_1 \\x_2 &= -3x_1 + 5x_3 + e_2 \\x_3 &= e_3\end{aligned}$$



- ・ 因果順序  $k(3) = 1, k(1) = 2, k(2) = 3$  で並び替え


$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ -3 & 0 & 5 \\ 0 & 0 & 0 \end{bmatrix}}_B \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}}_x + \underbrace{\begin{bmatrix} e_1 \\ e_2 \\ e_3 \end{bmatrix}}_e$$

$$\underbrace{\begin{bmatrix} x_3 \\ x_1 \\ x_2 \end{bmatrix}}_{x_{\text{後}}} = \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 5 & -3 & 0 \end{bmatrix}}_{B_{\text{後}}} \underbrace{\begin{bmatrix} x_3 \\ x_1 \\ x_2 \end{bmatrix}}_{x_{\text{後}}} + \underbrace{\begin{bmatrix} e_3 \\ e_1 \\ e_2 \end{bmatrix}}_{e_{\text{後}}}$$

# LiNGAMモデル

- ・ 構造方程式モデルと因果グラフ

$$\begin{aligned}x_1 &= e_1 \\x_2 &= -3x_1 + 5x_3 + e_2 \\x_3 &= e_3\end{aligned}$$



- ・ 因果順序  $k(3) = 1, k(1) = 2, k(2) = 3$  で並び替え

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ -3 & 0 & 5 \\ 0 & 0 & 0 \end{bmatrix}}_B \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}}_x + \underbrace{\begin{bmatrix} e_1 \\ e_2 \\ e_3 \end{bmatrix}}_e$$

$$\underbrace{\begin{bmatrix} x_1 \\ x_3 \\ x_2 \end{bmatrix}}_{x_{\text{後}}} = \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 5 & -3 & 0 \end{bmatrix}}_{B_{\text{後}}} \underbrace{\begin{bmatrix} x_1 \\ x_3 \\ x_2 \end{bmatrix}}_{x_{\text{後}}} + \underbrace{\begin{bmatrix} e_1 \\ e_3 \\ e_2 \end{bmatrix}}_{e_{\text{後}}}$$

# LiNGAMモデル

---

$$x = Bx + e$$




観測変数ベクトル $x$ について解く

$$(I - B)x = e$$



行列 $I - B$ の逆行列を両辺にかける

$$(I - B)^{-1}(I - B)x = (I - B)^{-1}e$$



$(I - B)^{-1} = A$ とおく

$$\begin{aligned} x &= (I - B)^{-1}e \\ &= Ae \end{aligned}$$

- ( $p$ 次元ベクトル)  $x$ : 観測変数ベクトル
- ( $p \times p$ の行列)  $B$ : 係数行列
- ( $p$ 次元ベクトル)  $e$ : 誤差変数ベクトル

※誤差変数ベクトル $e$ の成分 $e_i (i = 1, \dots, p)$ は独立、かつ、それぞれ非ガウス連続分布に従う

# LiNGAMモデル

---

- LiNGAMモデル

$$\begin{aligned}x_1 &= e_1 \\x_2 &= b_{21}x_1 + e_2\end{aligned}$$

- 行列表現

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} 0 & 0 \\ b_{21} & 0 \end{bmatrix}}_B \underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x + \underbrace{\begin{bmatrix} e_1 \\ e_2 \end{bmatrix}}_e$$


# LiNGAMモデル

---

$$\underbrace{\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}}_x = \underbrace{\left( \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 0 & 0 \\ b_{21} & 0 \end{bmatrix} \right)^{-1}}_{(I - B)^{-1}} \underbrace{\begin{bmatrix} e_1 \\ e_2 \end{bmatrix}}_e$$

$$= \underbrace{\begin{bmatrix} 1 & 0 \\ -b_{21} & 1 \end{bmatrix}^{-1}}_{W^{-1}} \underbrace{\begin{bmatrix} e_1 \\ e_2 \end{bmatrix}}_e$$

$$= \underbrace{\begin{bmatrix} 1 & 0 \\ b_{21} & 1 \end{bmatrix}^{-1}}_A \underbrace{\begin{bmatrix} e_1 \\ e_2 \end{bmatrix}}_e$$



ここより

$$W = \begin{bmatrix} 1 & 0 \\ -b_{21} & 1 \end{bmatrix}$$

# LiNGAMモデル

---

対角行列

$$D = \begin{bmatrix} d_{11} & 0 \\ 0 & d_{22} \end{bmatrix} \quad DW = \begin{bmatrix} d_{11} & 0 \\ -d_{22}b_{21} & d_{22} \end{bmatrix}$$

置換行列

$$P_{12} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad P_{12}DW = \begin{bmatrix} -d_{22}b_{21} & d_{22} \\ d_{11} & 0 \end{bmatrix}$$

# LiNGAMモデル

---

$$\begin{aligned} W_{ICA} &= P_{12}DW \\ &= \begin{bmatrix} -d_{22}b_{21} & d_{22} \\ d_{11} & 0 \end{bmatrix} \end{aligned}$$

←行の順序が正しくない

$$\begin{aligned} \tilde{P}W_{ICA} &= \tilde{P}P_{12}DW \\ &= \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} -d_{22}b_{21} & d_{22} \\ d_{11} & 0 \end{bmatrix} \\ &= \begin{bmatrix} d_{11} & 0 \\ -d_{22}b_{21} & d_{22} \end{bmatrix} \end{aligned}$$