

変分ベイズ推定

B8EM1016 富田優

変分ベイズ推定(Variational Bayesian(VB) method)とは、確率モデルの潜在変数や事後分布のパラメータを求める手法。確率モデルを直接解くのではなく、因子分解という仮定を置くことで計算を容易にしている。積分の近似としてサンプリングを用いる MCMC と異なり、パラメータを解析的に解いているので決定論的である(データを与えれば一意にパラメータが求まる)。

以上の2点(①因子分解という過程 ②解析的に解く)をもって、決定論的な近似アルゴリズムと言われる。

以下では変分ベイズ推定を説明する準備として、

1.KL 情報量

2.変分法

を説明する。

1.KL 情報量

統計モデルの「近さ」を表す指標としてカルバック・ライブラー情報量がある。

$$KL[p^*(x)||p(x|\Phi)] = \int p^*(x) \log \frac{p^*(x)}{p(x|\Phi)} dx$$

KL 情報量には以下の性質がある。

$$KL[p^*(x)||p(x|\Phi)] \geq 0$$

$$KL[p^*(x)||p(x|\Phi)] = 0 \leftrightarrow p^*(x) = p(x|\Phi)$$

2.変分法

変分法とは、関数 f を入力とする汎関数 $L[f(x)]$ の極値となる関数 f を求めるための方法である。つまり、

$$\frac{\partial L[f]}{\partial f} = 0$$

となる関数を求める方法である。

ここで、関数 $f(x)$ が関数 $q(x)$ によって構成されている場合に、明示的に $f(x, q)$ と書くことにする。例えば、 $f(x) = -q(x) \log q(x)$ という関数を $f(x, q)$ などと書く。この表現を用いて汎関数を以下のように定義する。

$$L[q(x)] = \int f(x, q) dx$$

この汎関数の極値を与えるは、以下のオイラー・ラグランジュ方程式を解けばよい。

$$\frac{\partial f(x, q)}{\partial q(x)} = 0$$

3.変分ベイズ推定

一般的なモデルにおける変分ベイズ法の導出を説明する。

モデルの生成過程

$$x_i \sim p(x_i | \varphi_{z_i}), z_i \sim \text{Multi}(z_i | \pi), \varphi_k \sim p(\varphi_k | \eta), \pi \sim \text{Dir}(\pi | \alpha).$$

3.1 事後分布の計算

求めたい事後分布 $q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})$ を解析的に求めることは困難なので、**因子分解**が可能という過程を置いて、以下の近似事後分布を解くことを考える。

$$q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi}) = \prod_{i=1}^n q(z_i) \prod_{k=1}^K q(\varphi_k) q(\boldsymbol{\pi})$$

また、確率分布間の近さとして KL 情報量を用いれば、近似事後分布の推定は以下の最適化問題として定式化できる。

$$q^*(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi}) = \underset{q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi}) \in \Omega}{\operatorname{argmin}} KL[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi}) || p(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi} | \mathbf{x}_{1:n}, \boldsymbol{\alpha}, \boldsymbol{\eta})]$$

しかし、上記の式には計算の困難な $p(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi} | \mathbf{x}_{1:n}, \boldsymbol{\alpha}, \boldsymbol{\eta})$ が含まれているため、効率的に解くことができない。この問題を直接最適化することは難しいが、以下の対数周辺尤度を利用して、最適化問題の式を直接解かずに $q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})$ を導出できる。

$$\log p(\mathbf{x}_{1:n} | \boldsymbol{\alpha}, \boldsymbol{\eta}) = \log \int \sum_{\mathbf{z}_{1:n}} p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi} | \boldsymbol{\alpha}, \boldsymbol{\eta}) d\boldsymbol{\varphi} d\boldsymbol{\pi}$$

3.2 対数周辺尤度の展開

$$\log p(\mathbf{z}_{1:n} | \boldsymbol{\alpha}, \boldsymbol{\eta}) = F[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})] + KL[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi}) || p(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi} | \mathbf{x}_{1:n}, \boldsymbol{\alpha}, \boldsymbol{\eta})]$$

ただし、

$$F[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})] = \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi}) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi} | \boldsymbol{\alpha}, \boldsymbol{\eta})}{q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})} d\boldsymbol{\varphi} d\boldsymbol{\pi}$$

である。

3.3 イエンセンの不等式

ここで、イエンセンの不等式

$$\int f(y(x))p(x)dx \geq f\left(\int y(x)p(x)dx\right)$$

$p(x)$ ：実数上の確率分布 $y(x)$ ：実数上の可積分関数 $f(x)$ ：実数上の凸関数

を用いると

$$\log p(\mathbf{x}_{1:n}|\alpha, \eta) \geq F[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})]$$

である。

以上の式のとおり、対数周辺尤度の下限という意味で $F[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})]$ は変分下限(Variational lower-bound)と呼ばれている。

ここで重要なことは

$\log p(\mathbf{z}_{1:n}|\alpha, \eta)$ が $q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})$ とは無関係なことである。変分下限 $F[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})]$ を最大にする $q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})$ はKL 情報量を最小にする $q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})$ である。

3.4 近似事後分布が帰着する最適化問題

最終的に、変分ベイズ法は以下の最適化問題に帰着する。

$$q^*(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi}) = \underset{q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi}) \in \Omega}{\operatorname{argmax}} F[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})]$$

さらに細かく $F[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})]$ の展開を行う。

$$\begin{aligned} F[q(\mathbf{z}_{1:n}, \boldsymbol{\varphi}, \boldsymbol{\pi})] &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\varphi})q(\boldsymbol{\pi}) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\varphi}, \boldsymbol{\pi})p(\boldsymbol{\varphi}|\boldsymbol{\pi})p(\boldsymbol{\pi}|\alpha)}{q(\mathbf{z}_{1:n})q(\boldsymbol{\varphi})q(\boldsymbol{\pi})} d\boldsymbol{\varphi}d\boldsymbol{\pi} \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\varphi})q(\boldsymbol{\pi}) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\varphi}, \boldsymbol{\pi})}{q(\mathbf{z}_{1:n})} d\boldsymbol{\varphi}d\boldsymbol{\pi} + \sum_{k=1}^K \int q(\varphi_k) \log \frac{q(\varphi_k|\boldsymbol{\pi})}{q(\varphi_k)} d\varphi_k \\ &\quad + \int q(\boldsymbol{\pi}) \log \frac{q(\boldsymbol{\pi}|\alpha)}{q(\boldsymbol{\pi})} d\boldsymbol{\pi} \\ &= \int \sum_{\mathbf{z}_{1:n}} q(\mathbf{z}_{1:n})q(\boldsymbol{\varphi})q(\boldsymbol{\pi}) \log \frac{p(\mathbf{x}_{1:n}, \mathbf{z}_{1:n}|\boldsymbol{\varphi}, \boldsymbol{\pi})}{q(\mathbf{z}_{1:n})} d\boldsymbol{\varphi}d\boldsymbol{\pi} - \sum_{k=1}^K KL[q(\varphi_k||p(\varphi_k|\boldsymbol{\pi}))] \\ &\quad - KL[q(\boldsymbol{\pi})||p(\boldsymbol{\pi}|\alpha)] \end{aligned}$$

これで、求めたい $q(\mathbf{z}_{1:n}), q(\boldsymbol{\varphi}), q(\boldsymbol{\pi})$ を求めやすい形にすることができた。

3.5 変分法で解く

それでは、上記の式に変分法を用いて解く。

まずは、右辺第一項を展開すると

$$\begin{aligned}
 & \int \sum_{z_{1:n}} q(z_{1:n}) q(\varphi) q(\pi) \log \frac{p(x_{1:n}, z_{1:n} | \varphi, \pi)}{q(z_{1:n})} d\varphi d\pi \\
 &= \int \sum_{z_{1:n}} q(z_{1:n}) q(\varphi) q(\pi) \log p(x_{1:n}, z_{1:n} | \varphi, \pi) d\varphi d\pi - \int q(\varphi) q(\pi) d\varphi d\pi \sum_{z_{1:n}} q(z_{1:n}) \log q(z_{1:n}) \\
 &= \int \sum_{i=1}^n \sum_{z_i} q(z_i) q(\varphi) q(\pi) \log p(x_i, z_i | \varphi, \pi) d\varphi d\pi - \sum_{i=1}^n \sum_{k=1}^K q(z_i = k) \log p(z_i = k)
 \end{aligned}$$

となる。

ここで、 $F[q(z_{1:n}, \varphi, \pi)]$ の $q(z_i)$ に関係のある項のみを取り出して、それを $\tilde{F}[q(z_i)]$ とおくと

$$\tilde{F}[q(z_i)] = \sum_{k=1}^K q(z_i = k) \int q(\varphi) q(\pi) \log p(x_i, z_i = k | \varphi, \pi) d\varphi d\pi - \sum_{k=1}^K q(z_i = k) \log p(z_i = k)$$

となる。 $q(z_i = k)$ を変数とみなすと、上記の式は通常の微分法で解ける。また、

$$\sum_{k=1}^K q(z_i = k) = 1$$

となることを考慮すると、これは制約付き最適化問題なので、ラグランジュ未定乗数法を用いてこれを解くことになる。

式

$$L[q(z_i)] = \tilde{F}[q(z_i)] + \lambda \left(1 - \sum_{k=1}^K q(z_i = k) \right)$$

を $q(z_i)$ で微分すると、

$$\int q(\varphi) q(\pi) \log p(x_i, z_i = k | \varphi, \pi) d\varphi d\pi - \log p(z_i = k) - q(z_i = k) \frac{1}{q(z_i = k)} - \lambda = 0$$

$$\Leftrightarrow q(z_i = k) = \exp \left[-1 - \lambda + \int q(\varphi) q(\pi) \log p(x_i, z_i = k | \varphi, \pi) d\varphi d\pi \right]$$

ラグランジュ関数を λ で微分して得られた

$$\sum_{k=1}^K q(z_i = k) = 1$$

に上の式を代入すると

$$q(z_i = k) = \frac{\exp \left[\int q(\varphi) q(\pi) \log p(x_i, z_i = k | \varphi, \pi) d\varphi d\pi \right]}{\sum_{k'=1}^K \exp \left[\int q(\varphi) q(\pi) \log p(x_i, z_i = k' | \varphi, \pi) d\varphi d\pi \right]}$$

となる。

○ポイント

「事後分布の計算を結合分布の計算に帰着させる」

変分ベイズ法では、変分下限という形で、事後分布の計算を結合分布の計算に帰着させている

4.LDA の変分ベイズ法

要点

目的：KL[$p(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi} | \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\beta}) || q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})$]を最小にする $q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})$ を求める

手法：対数周辺尤度 $p(\mathbf{w} | \boldsymbol{\alpha}, \boldsymbol{\beta})$ の変分下限 $F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})]$ を導出し、 $F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})]$ を最大にする $q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})$ を変分法により求める。

変分下限の導出プロセスは

- 1.周辺化された確率変数を結合分布として積分系で表示する。
- 2.変分事後分布を分子分母でキャンセルする形で導入する。
- 3.イエンセンの不等式により下限を求める。

$$\begin{aligned}\log p(\mathbf{w} | \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \log \int \sum_{\mathbf{z}} p(\mathbf{w}, \mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi} | \boldsymbol{\alpha}, \boldsymbol{\beta}) d\boldsymbol{\theta} d\boldsymbol{\varphi} \\ &= \log \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi}) \frac{p(\mathbf{w}, \mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi} | \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})} d\boldsymbol{\theta} d\boldsymbol{\varphi} \\ &\geq \int \sum_{\mathbf{z}} q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi}) \log \frac{p(\mathbf{w}, \mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi} | \boldsymbol{\alpha}, \boldsymbol{\beta})}{q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})} d\boldsymbol{\theta} d\boldsymbol{\varphi} \equiv F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})]\end{aligned}$$

ここで近似事後分布として

$$q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi}) = \left[\prod_{d=1}^M \prod_{i=1}^{n_d} q(z_{d,i}) \right] \left[\prod_{d=1}^M q(\theta_d) \right] \left[\prod_{k=1}^K q(\varphi_k) \right]$$

以上の因子分解の仮定を置く。

$$\begin{aligned}F[q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})] &= \int \sum_{\mathbf{z}} q(\mathbf{z}) q(\boldsymbol{\theta}) q(\boldsymbol{\varphi}) \log p(\mathbf{w} | \mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi}) p(\mathbf{z} | \boldsymbol{\theta}) d\boldsymbol{\theta} d\boldsymbol{\varphi} - \sum_{\mathbf{z}} q(\mathbf{z}) \log q(\mathbf{z}) \\ &\quad - \int q(\boldsymbol{\theta}) \log \frac{p(\boldsymbol{\theta} | \boldsymbol{\alpha})}{q(\boldsymbol{\theta})} d\boldsymbol{\theta} - \int q(\boldsymbol{\varphi}) \log \frac{p(\boldsymbol{\varphi} | \boldsymbol{\beta})}{q(\boldsymbol{\varphi})} d\boldsymbol{\varphi}\end{aligned}$$

$$\begin{aligned}
&= \int \sum_{d=1}^M \sum_{i=1}^{n_d} q(z_{d,i}) q(\theta_d) q(\varphi) \log p(w_{d,i}|z_{d,i}, \varphi) p(z_{d,i}|\theta_d) d\varphi d\theta \\
&\quad - \sum_{d=1}^M \sum_{i=1}^{n_d} \sum_{k=1}^K q(z_{d,i} = k) \log q(z_{d,i} = k) + \sum_{d=1}^M - \int q(\theta_d) \log \frac{p(\theta_d|\alpha)}{q(\theta_d)} d\theta_d \\
&\quad + \sum_{k=1}^K - \int q(\varphi_k) \log \frac{p(\varphi_k|\beta)}{q(\varphi_k)} d\varphi_k
\end{aligned}$$

以下、 $F[q(z, \theta, \varphi)]$ を最大にする $q(\mathbf{z}, \boldsymbol{\theta}, \boldsymbol{\varphi})$ を変分法に求める。

まず、 $F[q(z, \theta, \varphi)]$ から $q(\theta_d)$ に関係する項のみを抜き出した $\tilde{F}[q(\theta_d)]$ は

$$\tilde{F}[q(\theta_d)] = \int q(\theta_d) \sum_z q(z) \sum_{i=1}^{n_d} \log p(z_{d,i}|\theta_d) d\theta_d - \int q(\theta_d) \log \frac{q(\theta_d)}{p(\theta|\alpha)} d\theta_d$$

である。

汎関数 $\tilde{F}[q(\theta_d)] = \int f(\theta_d, q(\theta_d)) d\theta_d$ と見れば、

$$\frac{\delta \tilde{F}[q(\theta_d)]}{\delta q(\theta_d)} = 0$$

となる $q(\theta_d)$ は、変分法により

$$\frac{\partial f(\theta_d, q(\theta_d))}{\partial q(\theta_d)} = 0$$

となる $q(\theta_d)$ をお願い致します。求めればよいので

$$\frac{\partial f(\theta_d, q(\theta_d))}{\partial q(\theta_d)} = \sum_z q(z) \sum_{i=1}^{n_d} \log p(z_{d,i}|\theta_d) - \log \frac{q(\theta_d)}{p(\theta_d|\alpha)} - 1 = 0$$

$$\Leftrightarrow q(\theta_d) \propto p(\theta_d|\alpha) \exp \left[\sum_z q(z) \sum_{i=1}^{n_d} \log p(z_{d,i}|\theta_d) \right]$$

ここで、

$$\begin{aligned}
q(\theta_d|\alpha) &\propto \prod_{k=1}^K \theta_{d,k}^{\alpha_k-1} \\
E_{q(z_d)}[n_{d,k}] &= \sum_{i=1}^{n_d} q(z_{d,i} = k) \\
p(z_{d,i}|\theta_d) &= \prod_{k=1}^K \theta_{d,k}^{\delta(z_{d,i}=k)}
\end{aligned}$$

を用いると

$$\propto \prod_{k=1}^K \theta_{d,k}^{\alpha_k-1} \exp \left[\sum_z q(z) \sum_{i=1}^{n_d} \sum_{k=1}^K \delta(z_{d,i} = k) \log \theta_{d,k} \right]$$

$$\begin{aligned}
&= \exp \left[\sum_{k=1}^K (\alpha_k - 1) \log \theta_{d,k} \right] \exp \left[\sum_{k=1}^K \sum_{i=1}^{n_d} q(z_{d,i} = k) \log \theta_{d,k} \right] \\
&= \exp \left[\sum_{k=1}^K (\alpha_k - 1) \log \theta_{d,k} \right] \exp \left[\sum_{k=1}^K E_{q(z_d)}[n_{d,k}] \log \theta_{d,k} \right] \\
&= \exp \left[\sum_{k=1}^K (E_{q(z_d)}[n_{d,k}] + \alpha_k - 1) \log \theta_{d,k} \right] \\
&= \prod_{k=1}^K \theta_{d,k}^{E_{q(z_d)}[n_{d,k}] + \alpha_k - 1}
\end{aligned}$$

ここで

$$\xi_{d,k}^\theta = E_{q(z_d)}[n_{d,k}] + \alpha_k$$

とおくと式から、 $q(\theta_d)$ は $\xi_d^\theta = (\xi_{d,1}^\theta, \xi_{d,2}^\theta, \dots, \xi_{d,K}^\theta)$ をパラメータとするディリクレ分布であることが分かる。従って、正規化項の計算も容易で、

$$q(\theta_d | \xi_d^\theta) = \frac{\Gamma(\sum_{k=1}^K \xi_{d,k}^\theta)}{\prod_{k=1}^K \Gamma(\xi_{d,k}^\theta)} \prod_{k=1}^K \theta_{d,k}^{\xi_{d,k}^\theta - 1}$$

と求めることができる。

引用：トピックモデルによる統計的潜在意味解析：奥村学、佐藤一誠(2013)